Nama: Syava Aprilia Puspitasari

NIM: 2241760129

# Spark SQL, DataSources, DataFrame, dan Dataset APIs

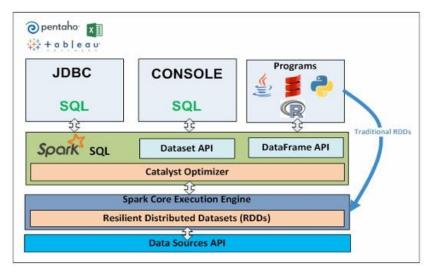
# Tujuan Pembelajaran

- 1. Memahami konsep **Spark SQL** dan kegunaannya dalam pemrosesan data terstruktur.
- 2. Menguasai penggunaan **DataFrame** dan **Dataset APIs** untuk manipulasi data.
- 3. Mempelajari berbagai DataSources yang didukung Spark (JSON, CSV, Parquet, JDBC, dll.).
- 4. Membangun pipeline ETL sederhana menggunakan Spark SQL.

## 1. Pengenalan Spark SQL

Spark SQL adalah modul Apache Spark untuk pemrosesan data terstruktur. Fitur utamanya:

- DataFrame & Dataset API: Abstraksi data terstruktur dengan optimasi query.
- **SQL Support**: Eksekusi query SQL standar.
- Data Source API: Integrasi dengan berbagai format data (JSON, CSV, Parquet, Hive, JDBC, dll.).
- Optimasi dengan Catalyst Optimizer: Meningkatkan performa query secara otomatis.



Gambar. Arsitektur Spark SQL

## 2. DataFrame & Dataset APIs

#### Perbedaan DataFrame dan Dataset

DataFrame	Dataset
Koleksi data terdistribusi dalam bentuk <i>row</i> dengan skema	Koleksi data terdistribusi dengan tipe stronglytyped (Scala/Java)
Optimasi eksekusi (Tungsten, Catalyst)	Memiliki keunggulan type-safety (compile-time checking)
Dibangun di atas RDD	Hanya tersedia di Scala & Java

#### **Contoh Pembuatan DataFrame**

```
[1]: from pyspark.sql import SparkSession

spark = SparkSession.builder.appName("DataFrameDemo").getOrCreate()

# Membuat DataFrame dari list
data = [("Alice", 25), ("Bob", 30), ("Charlie", 35)]
df = spark.createDataFrame(data, ["name", "age"])
df.show()
```

```
| name|age|
+-----+
| Alice| 25
| Bob| 30
|Charlie| 35
```

# 3. DataSources di Spark

Spark mendukung berbagai format data:

- JSON
- CSV
- Parquet (format kolumnar yang efisien)
- JDBC (koneksi database relasional)
- Avro, ORC, Hive, dll.

## **Contoh Membaca & Menulis Data**

```
# Baca file CSV
```

```
df_csv = spark.read.csv("data.csv", header=True, inferSchema=True)

# Baca file JSON
df_json = spark.read.json("data.json")

# Baca dari Parquet
df_parquet = spark.read.parquet("data.parquet")

# Simpan DataFrame ke format berbeda
df.write.mode("overwrite").parquet("output.parquet")
```

#### 4. Operasi DataFrame & SQL

#### Transformasi DataFrame

```
# Filter data
df_filtered = df.filter(df["age"] > 30)

# Select kolom
df_selected = df.select("name", "age")

# GroupBy & Aggregasi
df_grouped = df.groupBy("name").agg({"age": "avg"})

# Join DataFrame df_join = df1.join(df2, df1["id"] == df2["id"],
"inner")
```

#### Menggunakan SQL Query

```
# Daftarkan DataFrame sebagai temporary view

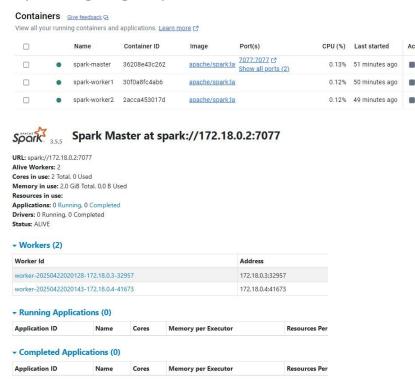
df.createOrReplaceTempView("people")

# Eksekusi query SQL result = spark.sql("SELECT name, age FROM people

WHERE age > 30")

result.show()
```

## Siapkan lingkungan Spark Cluster

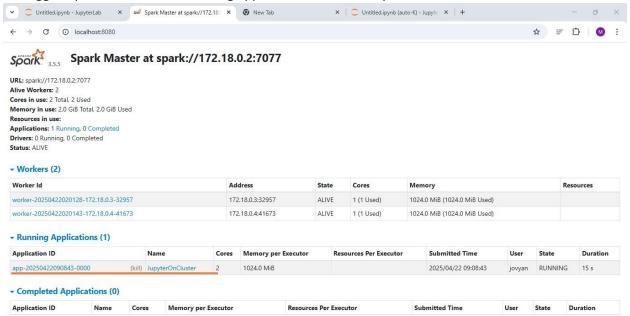


# Jalankan Jupyter notebook dengan network yang sama dengan spark cluster, dan daftarkan environtment spark cluster

PS C:\Users\Acer> docker run -it -p 8888:8888 -p 4040:4040 --network spark-net -e SPARK\_MASTER=spark://spark-master:7077 jupy ter/all-spark-notebook

# Buat spark session yang menggunakan spark cluster untuk lingkungan eksekusi

#### Sehingga dapat kita lihat ada 1 running application di halaman Spark UI



# 5. Praktikum: Membangun ETL Pipeline

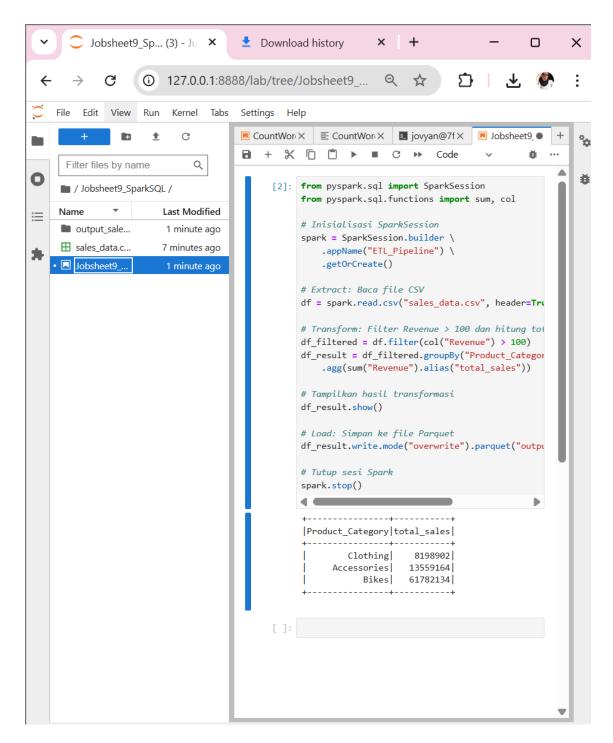
#### **Tugas**

- 1. Extract: Baca data dari file CSV (sales\_data.csv).
- 2. Transform:
  - Filter transaksi dengan Revenue > \$100.
  - Hitung total penjualan per kategori.
- 3. **Load**: Simpan hasil ke Parquet.

#### Solusi

```
[*]: from pyspark.sql import SparkSession
      import os
      from pyspark.sql.functions import month, sum, count, col
      spark = SparkSession.builder \
         .master("spark://spark-master:7077") \
          .appName("JupyterOnCluster") \
         .config("spark.driver.host", os.environ.get('SPARK_DRIVER_HOST', 'localhost')) \
         .config("spark.driver.port", "8888") \
.config("spark.ui.port", "4040") \
         .config("spark.executor.memory", "1g") \
.config("spark.cores.max", "2") \
          .getOrCreate()
      df = spark.read.csv("sales_data.csv", header=True, inferSchema=True)
      # Transform
     df_filtered = df.filter(col("Revenue") > 100)
      df_result = df_filtered.groupBy("Product_Category").agg(sum("Revenue").alias("total_sales"))
      df_result.show()
      # Load
      df_result.write.mode("overwrite").parquet("output_sales.parquet")
                                                                                                         Woul
      spark.stop()
```

<mark>Jawab:</mark>



## 6. Analisis Data Retail

#### **Dataset**

Format: CSV (sales\_data.csv)

## **Tugas**

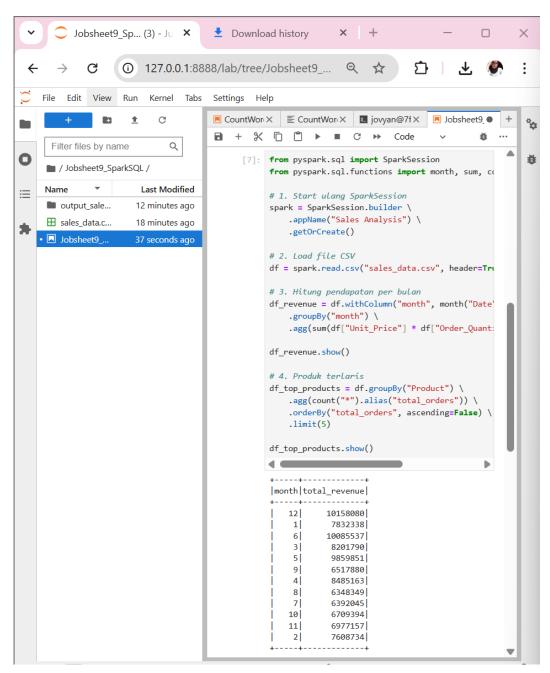
- 1. Hitung total pendapatan per bulan.
- 2. Identifikasi 5 produk terlaris.
- 3. Simpan hasil dalam format Parquet.

#### Solusi

1. Pendapatan perbulan

```
|month|total_revenue|
+----+
  12 10158080
   1 7832338
   6 10085537
   3 8201790
        9859851
6517880
8485163
6348349
   5
   91
   4
   8
        6392045
   7
        6709394
  10
        6977157
  11
```

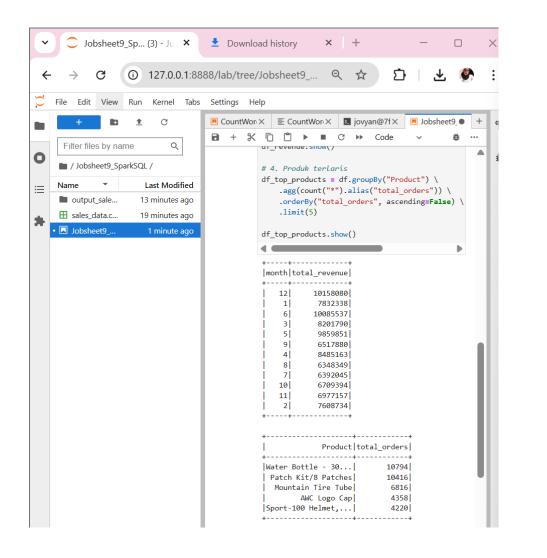
<mark>Jawab:</mark>



2. Identifikasi 5 Produk terlaris

```
[10]: # 5 produk terlaris
     df_top_products = df.groupBy("Product") \
                     .agg(count("*").alias("total_orders")) \
                     .orderBy("total_orders", ascending=False) \
                     .limit(5)
     df_top_products.show()
     +----+
               Product|total_orders|
       -----+
     |Water Bottle - 30...|
                           10794
     | Patch Kit/8 Patches|
                          10416
     | Mountain Tire Tube|
                           6816
         AWC Logo Cap
                           4358
     |Sport-100 Helmet,...|
                           4220
     +----+
```

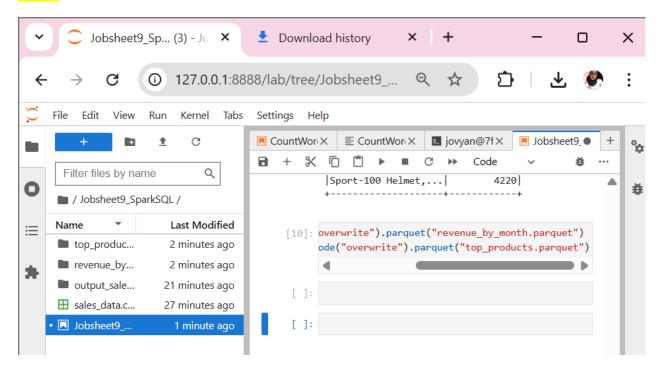
#### <mark>Jawab:</mark>



3. simpan dalam format parquet



#### Jawab:



## 7. Evaluasi

#### **Soal Latihan**

1. Baca data dari table di database MySQL anda menggunakan Spark, dengan cara berikut

```
df = spark.read.format("jdbc") \
    .option("url", "jdbc:mysql://localhost:3306/db") \
    .option("dbtable", "table_name") \
    .option("user", "user") \
    .option("password", "password") \
```

.load()	
Baca table apa saja.	

2. Buat query Spark SQL untuk menghitung Jumlah row dalam table tersebut

# Kesimpulan

- Spark SQL menyediakan antarmuka terstruktur untuk pemrosesan data besar.
- DataFrame & Dataset APIs memungkinkan manipulasi data dengan sintaks mirip SQL.
- DataSources API mendukung integrasi dengan berbagai format penyimpanan.